

# Aprendiendo a jugar a Oteló: Agente Inteligente con Búsqueda Adversaria y Deep Learning

1<sup>st</sup> Javier Luque Ruiz

Grado en Ingeniería Informática - Ingeniería del Software

Universidad de Sevilla

Sevilla, España

javluqrui@alum.us.es

**Resumen**—En este trabajo se explorará el desarrollo de un agente inteligente para el clásico juego de tablero Oteló (Reversi). El objetivo principal es construir un jugador capaz de tomar decisiones estratégicas mediante la implementación del algoritmo clásico de Minimax con poda alfa-beta para explorar el espacio de decisiones. Adicionalmente, se integrará una red neuronal profunda entrenada mediante autojuego para proporcionar una heurística de evaluación de las posiciones intermedias, reemplazando las funciones de evaluación manuales clásicas.

**Index Terms**—Inteligencia Artificial, Oteló, Reversi, Minimax, Poda Alfa-Beta, Deep Learning, Python.

## I. INTRODUCCIÓN

El desarrollo de agentes inteligentes capaces de tomar decisiones estratégicas en juegos de tablero ha sido uno de los grandes hitos de la Inteligencia Artificial. Inspirado en los éxitos recientes de sistemas basados en aprendizaje profundo, este trabajo explora la combinación de algoritmos de búsqueda clásica con técnicas modernas de redes neuronales.

El objetivo principal de este proyecto es construir un agente inteligente para el clásico juego de Oteló (también conocido como Reversi). Específicamente, se aborda la variante del proyecto correspondiente a la convocatoria de julio, la cual requiere la implementación del algoritmo Minimax con poda alfa-beta para explorar el espacio de decisiones. La aportación central del sistema consiste en sustituir las funciones heurísticas manuales por una red neuronal profunda, la cual aprenderá a evaluar las posiciones intermedias del tablero basándose en un conjunto de datos generado mediante partidas de autojuego.

## II. PREELIMINARES

### II-A. El juego de Oteló

Oteló es un juego de estrategia de suma cero con información perfecta para dos jugadores, el cual se disputa sobre un tablero de  $8 \times 8$  casillas, siguiendo el reglamento oficial de la Federación Mundial de Oteló [2]. La partida inicializa con una disposición central de cuatro fichas cruzadas (dos blancas y dos negras), cediendo el primer movimiento al jugador con las piezas negras.

La mecánica central del juego es el *flanqueo*: un movimiento legal consiste en colocar una ficha en una casilla vacía de forma que, en línea recta (horizontal, vertical o diagonal), una o más piezas del oponente queden atrapadas




Figura 1. Tablero inicial de Oteló con la disposición central de fichas.

entre la nueva ficha y otra pieza del jugador activo. Las fichas flanqueadas son capturadas y cambian de color.

Para ilustrar esta mecánica, la Fig. 2 muestra las casillas vacías donde el jugador con fichas negras puede colocar su pieza en el primer turno de la partida. Cada una de estas posiciones permite flanquear al menos una ficha blanca, cumpliendo así con la regla de legalidad del movimiento. Por el contrario, las casillas marcadas en rojo representan un movimiento ilegal, ya que, aunque estén adyacentes a fichas del oponente, colocar una ficha ahí no lograría atrapar ninguna ficha blanca entre dos fichas negras.




Figura 2. Ejemplo de movimientos: flanqueo válido (verde) y movimiento ilegal (rojo).

Siguiendo con el escenario planteado, supongamos que el jugador de piezas negras decide ejecutar el movimiento válido situado más a la izquierda del tablero. Al colocar su ficha en esa posición, logra atrapar una pieza blanca del oponente contra otra de sus propias fichas negras situadas en el centro.

Como dicta la regla del flanqueo, esta ficha blanca es capturada y revertida al color negro. El resultado de esta acción se ilustra en la Fig. 3. Tras este cambio en el tablero, el turno pasa inmediatamente al jugador de piezas blancas, continuando así el flujo natural de la partida.




Figura 3. Estado del tablero tras ejecutar el flanqueo. La ficha blanca capturada cambia a color negro.

Esta restricción de movimientos obliga a los jugadores a desarrollar estrategias de posicionamiento a largo plazo. En este sentido, el control de las esquinas del tablero resulta vital, ya que una ficha colocada en una de las cuatro esquinas jamás podrá ser flanqueada por el oponente, garantizando su permanencia hasta el final de la partida. Del mismo modo, limitar la movilidad del rival (reduciendo sus opciones legales) es una táctica fundamental para forzarle a realizar movimientos perjudiciales.

Si en algún momento un jugador carece de movimientos legales que cumplan esta regla de flanqueo, está obligado a pasar su turno. La partida concluye cuando el tablero se llena o ningún jugador puede realizar un movimiento válido, resultando ganador aquel con mayor número de fichas de su color.

## II-B. Búsqueda Adversaria y Poda Alfa-Beta

El desarrollo de un agente capaz de competir en juegos de tablero bidireccionales y de suma cero se fundamenta tradicionalmente en la teoría de la búsqueda adversaria [1]. En este contexto, el algoritmo Minimax constituye la técnica esencial para modelar la toma de decisiones estratégicas. Este enfoque asume que ambos jugadores actúan de forma completamente óptima bajo roles contrapuestos: el agente inteligente adopta el rol de maximizador (MAX), cuyo objetivo es seleccionar el movimiento que maximice su recompensa final, mientras que el oponente actúa como minimizador (MIN), intentando reducir a toda costa el beneficio de MAX.

El proceso opera de forma recursiva construyendo un árbol de juego, donde los nodos representan los estados del tablero y las aristas corresponden a los movimientos legales posibles. Los valores de utilidad se calculan desde los nodos terminales (hojas) y se propagan hacia arriba a través de los niveles del árbol: un nodo en un nivel MAX heredará el valor máximo de sus hijos, mientras que un nodo en un nivel MIN heredará el valor mínimo.

Sin embargo, el espacio de estados de Othello es masivo, con un factor de ramificación medio elevado. Explorar el árbol completo hasta el final de la partida desde los primeros turnos es computacionalmente inabarcable en tiempo real. Por ello, se implementa una estrategia de búsqueda con corte de profundidad (*cutting-off search*). Al alcanzar un límite preestablecido de niveles (profundidad  $d$ ), la simulación se detiene de manera controlada y se invoca una función heurística de evaluación numérica. Esta función estima de forma estática la calidad de la posición actual del tablero para MAX, sustituyendo el valor de utilidad real del fin de la partida.

Para mitigar el coste computacional y permitir exploraciones más profundas en menores tiempos de respuesta, se integra la optimización de la poda alfa-beta. Esta técnica mantiene el control de los peores escenarios asumibles por cada jugador durante la exploración recursiva mediante dos variables adaptativas:

- $\alpha$ : Representa la mejor opción (el valor más alto) que el jugador MAX ha logrado asegurar hasta el momento a lo largo del camino de búsqueda.
- $\beta$ : Representa la mejor opción (el valor más bajo) que el jugador MIN ha conseguido asegurar hasta el momento.

A medida que el algoritmo recorre el árbol en profundidad, actualiza estos valores. La poda (o descarte matemático de ramas) se ejecuta inmediatamente en el momento en que se cumple la condición:

$$\alpha \geq \beta \quad (1)$$

Esta desigualdad implica que el jugador actual puede forzar un resultado mejor en otra rama previamente explorada, por

lo que el oponente ideal jamás permitiría alcanzar el estado actual. Descartar estas ramas irrelevantes reduce drásticamente el número de nodos evaluados sin alterar en absoluto el movimiento óptimo final que devolvería el algoritmo Minimax puro.

Para comprender visualmente este proceso de descarte, la Fig. 4 ilustra el escenario conceptual diseñado para el árbol de decisión. Como se puede observar, tras evaluar el primer hijo de un nodo MIN y obtener un valor que resulta inferior o igual al valor  $\alpha$  asegurado por MAX, se activa inmediatamente el criterio de poda, omitiendo la exploración de los nodos restantes (marcados con un descarte explícito).




Figura 4. Ejemplo conceptual de poda alfa-beta en un árbol de búsqueda. Los nodos descartados se marcan con una cruz roja, indicando que no se evaluarán debido a la condición  $\alpha \geq \beta$ .

### III-C. Redes Neuronales y Deep Learning

Las redes neuronales artificiales son modelos computacionales inspirados en la estructura y el funcionamiento del cerebro humano, diseñados para aproximar funciones matemáticas complejas a partir de datos empíricos [3]. En particular, las redes con alimentación hacia adelante (*feed-forward neural networks*) se estructuran mediante unidades básicas denominadas neuronas, las cuales se organizan en capas secuenciales (entrada, ocultas y salida) [4].

Cada conexión entre neuronas posee un peso numérico asociado que modula la señal transmitida. Durante la fase de aprendizaje, estos pesos se ajustan iterativamente mediante algoritmos de optimización basados en el cálculo del gradiente, buscando minimizar una función de error o pérdida que mide la discrepancia entre la salida real de la red y el valor esperado [4].

En el contexto de este proyecto, el Aprendizaje Profundo (*Deep Learning*) se introduce para revolucionar el agente clásico de Minimax. En lugar de depender de una función

heurística manual estática (como el simple recuento de fichas), se entrena una red neuronal profunda para evaluar la calidad de los estados intermedios del tablero.

La red diseñada toma como entrada la representación matricial del tablero de  $8 \times 8$  y, tras procesar la información a través de sus capas ocultas mediante funciones de activación no lineales, devuelve un único valor continuo en el intervalo  $[-1, 1]$ . Esta salida representa la estimación de la posición: un valor cercano a 1 indica una alta probabilidad de victoria para el jugador activo, mientras que un valor cercano a  $-1$  augura una derrota inminente.

## III. IMPLEMENTACIÓN

### III-A. Motor del Juego

Para la representación del tablero de Othello se ha seleccionado una matriz bidimensional de  $8 \times 8$  elementos utilizando la librería NumPy. Esta decisión de diseño responde a la necesidad de gestionar los estados de forma eficiente y preparar los datos para su posterior tratamiento en la fase de Deep Learning.

De acuerdo con las especificaciones del enunciado del proyecto, se ha optado por utilizar la siguiente convención numérica para representar los distintos estados de las casillas:

- 0: Casilla vacía.
- 1: Casilla ocupada por una ficha blanca.
- 2: Casilla ocupada por una ficha negra.

La lógica de juego se encuentra en la clase *Othello*. La validación de los movimientos se realiza mediante la función *es\_movimiento\_valido*, cuyo funcionamiento se basa en escanear las ocho direcciones posibles desde la casilla seleccionada empleando tuplas de desplazamiento:

$$D = \{(0, 1), (1, 1), (1, 0), (1, -1), (0, -1), (-1, -1), (-1, 0), (-1, 1)\}$$

Un movimiento se considera legal si, al recorrer una dirección, se encuentra al menos una ficha del oponente seguida de una ficha propia, sin que haya casillas vacías intermedias ni se salga del tablero. El método *ejecutar\_movimiento* aprovecha esta lógica para almacenar las coordenadas de las piezas atrapadas y actualiza el tablero en consecuencia, revertiendo las fichas del oponente a las propias.

### III-B. Interfaz Gráfica y Máquina de Estados

La interacción con el usuario y la visualización del estado del juego se gestionan en el archivo *main.py* mediante la API gráfica de PyGame. Para evitar el acoplamiento de código y controlar de forma robusta el flujo de la aplicación, se ha diseñado una Arquitectura basada en una Máquina de Estados Estricta. El bucle principal del juego (*Game Loop*) evalúa de forma continua los eventos del sistema y renderiza la interfaz basándose en el estado activo:

- **MENU**: Pantalla de inicio que presenta el título y el botón para iniciar una nueva partida.
- **JUGANDO**: Estado activo durante el juego, donde se procesan los movimientos de los jugadores y se actualiza

la visualización del tablero. Cuenta con un panel inferior que muestra información relevante, como el turno actual y el marcador de fichas.

- **PASAR\_TURNO:** Estado crítico de validación que se activa cuando un jugador no tiene movimientos válidos disponibles, pero la partida continúa. En este estado, se notifica al jugador que está obligado a pasar turno mediante una confirmación explícita.
- **FIN:** Estado final que congela el estado del tablero y muestra el resultado de la partida, indicando el ganador o si ha habido un empate, así como el recuento final de fichas.

### III-C. Agente Inteligente: Minimax con Poda Alfa-Beta

Para dotar a la máquina de capacidad de decisión, se ha implementado un agente basado en el algoritmo Minimax complementado con la optimización de poda alfa-beta. Dado que el espacio de búsqueda de Othello es considerablemente grande, el algoritmo se ejecuta con una profundidad limitada. Al alcanzar dicha profundidad, se aplica una función heurística de evaluación manual básica, consistente en la diferencia de fichas entre el jugador maximizador y el minimizador.

Durante la implementación del agente, se identificaron y resolvieron dos desafíos arquitectónicos principales para asegurar la robustez del agente:

- **Gestión de turnos nulos en simulación:** En partidas avanzadas, es posible alcanzar estados donde un jugador no tiene movimientos válidos. Se implementó la lógica recursiva necesaria para que el agente ceda el turno de forma virtual en su árbol de búsqueda, en lugar de evaluar erróneamente esa rama como una derrota inmediata. Esto evita colapsos lógicos y la devolución de jugadas nulas al motor gráfico.
- **Ruptura del determinismo:** Al depender de una heurística simple de conteo de fichas, el agente podía generar movimientos repetitivos en situaciones de empate heurístico. Se introdujo un mecanismo de aleatorización en la selección de movimientos cuando múltiples opciones presentaban la misma evaluación. Esta imprevisibilidad es un requisito técnico fundamental para garantizar una generación de datos heterogénea y rica durante la fase de autójuego para el posterior entrenamiento de la red neuronal.

### III-D. Generación del Conjunto de Datos mediante Auto-juego

Para entrenar la red neuronal, es necesario disponer de un conjunto de datos etiquetado que relacione estados del tablero con la calidad de la posición para el jugador activo. Dado que no existen bases de datos públicas de partidas de Othello, se ha desarrollado un módulo de autójuego que enfrenta al agente Minimax contra sí mismo.

Se diseñó un entorno de simulación aislado de la interfaz gráfica donde dos agentes Minimax compiten entre sí. Durante la ejecución de cada partida, se registran los estados del tablero antes de cada movimiento junto al jugador activo.

Una vez finalizada la partida, se determina el ganador y se recorre el historial de estados para etiquetar cada posición con el resultado final desde la perspectiva del jugador activo en ese momento:

- **+1:** Si el jugador activo ganó la partida.
- **0:** Si la partida terminó en empate.
- **-1:** Si el jugador activo perdió la partida.

Aprovechando la aleatoriedad introducida previamente en el agente para romper el determinismo, se simularon 500 partidas completas de forma automatizada, generando una base de datos heterogénea de aproximadamente 30.000 tableros. Para optimizar el rendimiento de lectura durante la fase de entrenamiento, las estructuras de datos se transformaron en tensores y se exportaron en formato binario nativo (`.npy`) haciendo uso de la librería `NumPy`, separando las características de entrada (matrices de estado) de las etiquetas de salida.

### III-E. Arquitectura y Entrenamiento de la Red Neuronal

Una vez generado el conjunto de datos, se procedió a diseñar, compilar y entrenar una red neuronal profunda para aprender a evaluar las posiciones del tablero. Para ello, se utilizó la interfaz de `Keras` sobre el motor `TensorFlow`. Siguiendo un enfoque alineado con las prácticas de la asignatura, se implementó un modelo secuencial con la siguiente arquitectura:

- **Capa de Entrada y Aplanado:** Recibe la matriz del tablero de  $8 \times 8$  casillas, la cual es procesada mediante una capa de aplanado (`Flatten`) para convertirla en un vector unidimensional de 64 elementos.
- **Capas Ocultas:** Dos capas densas (`Dense`) con 64 y 32 neuronas respectivamente, ambas con función de activación `ReLU` para introducir no linealidad y evitar la saturación de gradientes.
- **Capa de Salida:** Una única neurona con función de activación de tangente hiperbólica (`tanh`), que devuelve un valor continuo en el rango  $[-1, 1]$ , representando la evaluación de la posición desde la perspectiva del jugador activo.

Para el proceso de optimización, se seleccionó el algoritmo de Descenso Estocástico por el Gradiente (SGD) con un factor de aprendizaje fijo de 0.01. La función de pérdida elegida fue el Error Cuadrático Medio (MSE), evaluada conjuntamente con la métrica del Error Absoluto Medio (MAE). El entrenamiento se llevó a cabo durante 50 épocas con un tamaño de lote de 256 ejemplos, aplicando una división de 80 % para entrenamiento y 20 % para validación.

## IV. PRUEBAS Y EXPERIMENTACIÓN

### IV-A. Estudio de Hiperparámetros y Selección del Modelo

Con el objetivo de optimizar la capacidad de generalización del modelo, en la fase de pruebas no se entrenó un único modelo, sino que se realizó un estudio comparativo evaluando tres configuraciones distintas de hiperparámetros.

Para garantizar la reproducibilidad del experimento, se fijaron las semillas de pseudoaleatoriedad (`seed = 42`) en las

librerías NumPy y TensorFlow, asegurando que el reparto del 20% de los datos de prueba fuera idéntico para todos los candidatos. Los tres modelos evaluados, todos con una estructura de 64 y 32 neuronas en sus capas ocultas, fueron los siguientes:

- **Modelo A:** Arquitectura base con función de activación *ReLU* y optimizador *SGD* con tasa de aprendizaje de 0.01.
- **Modelo B:** Mismo optimizador, pero sustituyendo *ReLU* por la función de activación *Sigmoide* en las capas ocultas.
- **Modelo c:** Arquitectura base (*ReLU*), pero sustituyendo el optimizador clásico por el algoritmo *Adam* con tasa de aprendizaje de 0.001, buscando una convergencia más rápida y estable.

Tras someter a los tres modelos a 50 épocas de entrenamiento, los resultados del error absoluto medio (MAE) sobre el conjunto de validación fueron los siguientes:

- Modelo A (Base): MAE de 0.9848
- Modelo B (Sigmoide): MAE de 0.9797
- Modelo C (Adam): MAE de 1.0384

El **Modelo C** experimentó un fenómeno de sobreajuste, con un error de validación superior al de entrenamiento, lo que indica que el optimizador *Adam* no fue capaz de generalizar adecuadamente en este caso. Por otro lado, el **Modelo B** mostró una ligera mejora respecto al modelo base. No obstante, el error cercano a 1.0 sugiere que la red no está aprendiendo patrones significativos y, ante la duda, tiende a predecir la situación del tablero como un empate (0). Esta limitación está relacionada con el uso de la capa *Flatten*, que no preserva la estructura espacial del tablero, dificultando que la red capture relaciones locales entre las fichas.

Como prueba final para descartar que el error del modelo se debiera a una falta de capacidad paramétrica o a un entrenamiento demasiado corto, se diseñó un experimento límite (Modelo D). Se construyó una topología masiva, incluyendo capas de *BatchNormalization* y *Dropout*, y se extendió el entrenamiento hasta las 500 épocas. Los resultados confirmaron el diagnóstico previo: la red alcanzó un error de entrenamiento bastante mejor que los previos (MAE de 0.7739), pero falló drásticamente en el conjunto de validación, disparando su error hasta 1.0058. Este comportamiento evidencia otro caso de sobreajuste. Al carecer de visión geométrica por el aplanado de los datos, y al tener tanta capacidad de memoria, la red optó por memorizar los tableros exactos del entrenamiento, perdiendo toda capacidad de generalizar reglas estratégicas.

A pesar de esta limitación, el **Modelo B** demostró ser la aproximación más estable y fue seleccionado como el modelo definitivo (*otelo\_B.keras*) para competir en el torneo final.

#### IV-B. Torneo Final: IA Clásica vs IA Híbrida

Para evaluar empíricamente el impacto de la red neuronal en la toma de decisiones, se diseñó un entorno de pruebas automatizado (*torneo.py*) donde se enfrentaron dos agentes:

- **Agente Clásico:** Implementación de Minimax con poda alfa-beta utilizando la heurística manual de conteo de fichas.
- **Agente Híbrido:** Implementación de Minimax con poda alfa-beta, pero reemplazando la heurística manual por la red neuronal entrenada (*otelo\_B.keras*).

Ambos agentes se configuraron con una profundidad máxima de búsqueda de 3 niveles. Para garantizar la equidad del enfrentamiento y mitigar la ventaja del primer movimiento, el torneo constó de 100 partidas consecutivas, garantizando que cada agente jugara 50 partidas con las fichas negras y 50 con las blancas.

Los resultados finales del torneo fueron un total de **72** victorias para el Agente Clásico, **23** victorias para el Agente Híbrido y **5** empates. Este resultado es coherente con el análisis previo: el Agente Clásico utiliza una heurística simple pero efectiva a niveles de profundidad bajos, mientras que el Agente Híbrido sufre de la falta de capacidad de generalización de la red neuronal que se comentó en la sección anterior. La red, al carecer de visión espacial, tiende a predecir empates, llevándolo a tomar decisiones inferiores frente a un oponente que evalúa de forma más directa la diferencia de fichas.

Sin embargo, el hecho de que el Agente Híbrido haya logrado 23 victorias y 5 empates frente a un oponente clásico indica que la red neuronal ha aprendido ciertos patrones estratégicos. La red neuronal no selecciona movimientos al azar, demostrando el éxito funcional de la integración de Deep Learning en el proceso de toma de decisiones.

## V. CONCLUSIONES

## VI. BIBLIOGRAFÍA

### REFERENCIAS

- [1] S. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed., Pearson, 2020, ch. 5, "Adversarial Search".
- [2] World Othello Federation, "Othello Rules," [Online]. Disponible en: <https://www.worldothello.org/about/about-othello/othello-rules>
- [3] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.
- [4] Dpto. de Ciencias de la Computación e Inteligencia Artificial, "Redes neuronales", Universidad de Sevilla, Apuntes de la asignatura Inteligencia Artificial, Curso 2025/2026.

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove the template text from your paper may result in your paper not being published.